

עבודת גמר בביולוגיה חישובית הסתברות מוטציות סרטניות בדומיינים פונקציונלים



מאת: שקד ברונדווין ואיל רייפלר
שם המנחה: ורד קוניק
תאריך הגשה: 18.6.2026



תמצית

עבודה זו בוחנת האם מוטציות סרטניות נוטות להופיע בתדירות גבוהה יותר בדומיינים פונקציונליים של חלבונים אונקוגניים, ואם כן, מדוע? לשם כך פותחה תוכנית בשפת פייתון שמחלצת נתוני מוטציות ממאגרי מידע, ממפה אותן על פי מיקומן בחלבון, ומנתחת את ההעדפה הסטטיסטית לדומיינים פונקציונליים באמצעות רגרסיה לוגיסטית.

תוכן עניינים

2	תמצית
3	תוכן עניינים
4	מבוא
4	הצגת הבעיה
4	מושגי יסוד
5	הקושי בפתרון הבעיה
6	מאגרי המידע
7	רקע עיוני
7	KRAS
8	EGFR
10	הצטברות מוטציות באזורים ספציפיים (Hotspots)
12	בחירת הדומיינים הפונקציונליים בחלבונים
12	הדומיינים הפונקציונליים בכל אחד מהחלבונים תחת ההיבטים השונים
12	היבט 1: ההגדרה הרשמית
13	היבט 2: ההגדרה שלנו
15	אנליזה
15	קבצי הפרויקט
15	עץ הקבצים
15	הסבר על כל קובץ
16	האלגוריתם הכללי של התוכנית
16	מודל הרגרסיה הלוגיסטית
16	פונקציות מרכזיות בתוכנית
20	הערכת שגיאות צפויות
21	תוצאות הרצת התוכנית
21	תוצאות ההרצה לפי ההגדרה הרשמית של דומיין פונקציונלי
24	תוצאות ההרצה לפי ההגדרה שלנו של דומיין פונקציונלי
27	אישוש
29	דיון בתוצאות
30	סיכום
31	ביבליוגרפיה
32	נספחים
32	הוראות להפעלת התוכנית
34	טופס דיווח לשימוש בכלי בינה מלאכותית

מבוא

הצגת הבעיה

סרטן הוא אחת המחלות השכיחות והקשות ביותר בעולם כיום, והבנת המנגנונים העומדים בבסיסו היא אחד האתגרים הגדולים בדרך למציאת תרופה לסוגי הסרטן השונים. ידוע כי סרטן נגרם על ידי מוטציות בגנים המווסתים את חלוקת התא וצמיחתו. עם זאת, לא כל מוטציה גורמת לסרטן, רק מוטציות באזורים ספציפיים ורגישים של החלבון עלולות להפוך תא תקין לתא סרטני. שאלת המחקר שלנו נובעת מכך: האם מוטציות סרטניות נוטות להופיע בשכיחות גבוהה יותר בדומיינים פונקציונליים של חלבונים אונקוגניים, ואם כן, מדוע?

לשם בחינת שאלה זו, בחרנו להתמקד בשני חלבונים מרכזיים ומתועדים מאוד: KRAS ו-EGFR. שני החלבונים הללו הם בין האונקוגנים השכיחים ביותר במחלות סרטן שונות, ביניהן סרטן הריאה, המעי הגס והבלב. KRAS הוא חלבון מסוג GTPase המתפקד כמתג מולקולרי הפועל בתוך התא, ואילו EGFR הוא קולטן חוצה ממברנה המקבל אותות גדילה מהסביבה החוץ-תאית. מוטציה בכל אחד מהם עלולה לגרום להפעלה בלתי פוסקת של מסלולי הצמיחה, ובכך לחלוקת תאים בלתי מבוקרת.

מושגי יסוד

כדי להבין את הבעיה לעומקה, יש להכיר מספר מושגים ביולוגיים מרכזיים:

שארית (Residue): יחידת בניין של חלבון (חומצת אמינו) כפי שהיא מופיעה בתוך שרשרת פוליפפטידית. המונח "שארית" משמש לציון מיקום ספציפי ברצף החלבון המקופל (למשל: "שארית 12").

דומיין פונקציונלי (Functional Domain): יחידה מבנית בתוך החלבון שיש לה תפקיד ספציפי (כמו קישור למולקולה אחרת או פעילות אנזימטית). חלבונים מורכבים לרוב מכמה דומיינים הפועלים יחד.

(בהמשך הספר יוצגו הרחבות ושינויים להגדרה זו)

מוטציה (Mutation): שינוי ברצף ה-DNA - המוביל לשינוי בחומצת האמינו בחלבון. מוטציות עלולות להשפיע על תפקוד החלבון ועל איכות ביצועו.

מוקד מוטציות (Hotspot): אזור ספציפי או עמדה מסוימת בחלבון שבהם מצטברות מוטציות בשכיחות גבוהה משמעותית משאר החלבון, לרוב בגלל שהן מעניקות יתרון הישרדותי לתא הסרטני.

אונקוגן (Oncogene): גן שבמצבו התקין מסייע לצמיחת התא, אך כתוצאה ממוטציה הופך לגן סרטני הגורם לחלוקת תאים בלתי מבוקרת.

רגרסיה לוגיסטית (Logistic Regression): מודל סטטיסטי המשמש לניבוי ההסתברות של משתנה בעל שני ערכים אפשריים. בעבודה זו, נעשה שימוש במודל זה לצורך נרמול והתחשבות באורך הדומיין.

פורמט FASTA: פורמט קובץ טקסט המשמש לייצוג רצפים של חומצות גרעין או רצפי חלבון. הרצף מתחיל בשורת הגדרה המתחילה בתו ">", ובשורות שאחריו מופיעות חומצות האמינו של הרצף. **חומצת אמינו (Amino Acid):** תרכובת אורגנית המהווה את יחידת הבניין הבסיסית של החלבונים. קיימות 20 חומצות אמינו בטבע, ורצף החיבור ביניהן קובע את המבנה התלת ממדי של החלבון ואת תפקודו.

הקושי בפתרון הבעיה

הבעיה אותה חקרנו נראית פשוטה לכאורה: לספור מוטציות ולבדוק היכן הן מצטברות. אולם בפועל, עמדנו בפני מספר אתגרים:

האתגר הראשון הוא כמות הנתונים. מאגרי המידע מכילים אלפי רשומות של מוטציות. לא ניתן לבדוק את הנתונים ידנית, ולכן היינו צריכים לכתוב תוכנית למחשב שתמצא את הנתונים הדרושים לנו בעצמה.

האתגר השני הוא הניתוח הסטטיסטי. לא ניתן פשוט לספור מוטציות ולהסיק מסקנות, שכן דומיין ארוך יותר יכול יותר מוטציות באקראי. יש צורך בכלי סטטיסטי שיתחשב באורך הדומיין. לשם כך השתמשנו ברגרסיה לינארית.

האתגר השלישי, ואולי המשמעותי ביותר, הוא חוסר הסכמה בהגדרת הדומיינים הפונקציונליים. על פי ההגדרה הרשמית של דומיין פונקציונלי, דומיין הוא אזור עצמאי שיכול להתקפל בעצמו ולעשות את תפקידו גם אם ינתקו אותו משאר החלבון. על פי הגדרה זו, בחלבון EGFR כמעט כל חומצות האמינו יהיו תחת דומיין פונקציונלי. כתוצאה מכך, הרגרסיה הלינארית לא תעבוד כראוי, שכן היא צריכה אזורים שאינם תחת דומיין פונקציונלי. לכן, יצרנו מדד שני שישתמש בהגדרה חדשה שנתנו לדומיין פונקציונלי. על פי הגדרה זו, דומיין פונקציונלי הינו אזור בחלבון שיש לו תפקיד ספציפי, אך לא דווקא עצמאי. על פי הגדרה זו, בחלבון EGFR יש הרבה אזורים שאינם תחת דומיין פונקציונלי, אך בחלבון KRAS רוב חומצות האמינו יהיו תחת דומיין פונקציונלי. אך מכיוון שחלבון EGFR גדול משמעותית מחלבון KRAS, התוצאות יהיו שונות מהמדד הראשון.

ללא המחשב לא היינו מצליחים למצוא את הפתרון. בעזרת המחשב הצלחנו לספור את כמות המוטציות בכל אזור, ולאחר מכן המחשב חישב לנו את הרגרסיה הלינארית. אם לא המחשב, היינו צריכים בעצמנו לנתח למעלה מ-1000 חומצות אמינו ולסווג מאות מוטציות בעצמנו. דבר שהיה דורש מאיתנו זמן רב, וסביר שגם התוצאה לא הייתה מדויקת.

מאגרי המידע

לצורך המחקר והפתרון נעשה שימוש במספר מאגרי מידע מרכזיים:

NCBI (The National Center for Biotechnology Information) הוא אחד המאגרים

הדיגיטליים הגדולים בעולם בתחום מדעי החיים והרפואה. יש בו מאגר עצום של מחקרים ומאמרים

מחוקרים מכל העולם בנושאי סרטן, חלבונים ומוטציות סרטניות. ממאגר זה לקחנו מאמרים

שהסבירו על הדומיינים והאזורים של שני החלבונים, ונתנו הרבה מידע על פעילות החלבונים

והמבנה שלהם.

UniProt הוא מאגר המידע המרכזי לחלבונים, המספק מידע מפורט על רצף החלבון, המבנה שלו,

הדומיינים ועוד. ממאגר זה הורדנו את קבצי שני החלבונים.

CBioPortal הוא פלטפורמה לניתוח נתוני סרטן. ממנה הורדנו את קבצי המוטציות של החלבונים,

שמכילים את מיקומי המוטציות בחלבונים אצל אנשים שחלו בסרטן.

רקע עיוני

הגנים **KRAS** ו-**EGFR** מתפקדים כמתגים ביולוגיים שאחראים על העברת אותות לצמיחת התא. המוטציות נוטות להופיע בדומינים שאחראים על כיבוי המתג או על הפעלתו (כמו דומיין ה-Tyrosine Kinase ב-EGFR או אתר קישור ה-GTP ב-KRAS). כאשר מתרחשת מוטציה בדיוק באזורים הרגישים הללו, המבנה המרחבי של החלבון משתנה כך שהוא נתקע במצב "פועל" קבוע. כתוצאה מכך, התא מקבל פקודה בלתי פוסקת להשתכפל ולהתחלק, מה שמוביל ליצירת גידול סרטני. הברירה הטבעית של הגידול משמרת דווקא את המוטציות בדומינים האלו כי הן אלו שמעניקות לתא את יתרון הצמיחה האגרסיבי ביותר.


KRAS

החלבון KRAS הוא GTPase חשוב המתפקד כמתג מולקולרי המעביר אותות לצמיחה וחלוקת תאים. המבנה שלו מחולק לשני חלקים עיקריים, כאשר הראשון הוא ה-G domain המקיף את שאריות חומצות האמינו 1 עד 166. דומיין זה מהווה את הלב הקטליטי של החלבון ומכיל את אתר הקישור לנוקליאוטידים GTP ו-GDP. בתוך ה-G domain נמצא ה-P loop, הממוקם בין שאריות 10 ל-14, שתפקידו המרכזי הוא לייצב את קבוצות הפוספט של הנוקליאוטיד הקשור. מוטציות בנקודה זו, במיוחד בעמדות 12 ו-13, הן מהגורמים השכיחים ביותר להפיכת החלבון לאונקוגני. לצד ה-P loop, ה-G domain כולל שני אזורים דינמיים המכונים switch I (שאריות 30-40) ו-switch II (שאריות 58-72). אזורים אלו משנים את צורתם המרחבית באופן קיצוני כאשר החלבון עובר ממצב כבוי למצב פעיל.

החלק השני של החלבון הוא ה-Hypervariable Region או בקיצור HVR. הוא משתרע משארית 167 ועד סוף הרצף בשארית 188. בניגוד ל-G domain היציב, ה-HVR הוא אזור גמיש ובלתי מקופל שתפקידו העיקרי הוא עיגון החלבון לממברנת התא, שם מתרחשת עיקר פעילותו. בקצה המרוחק של ה-HVR נמצא רצף ה-CAAX (שאריות 185-188), המשמש כאתר למודיפיקציות כימיות לאחר תגרום החלבון. בתהליך זה מתווספת קבוצה שומנית לשארית הציסטאין בעמדה 185, מה שמעניק לחלבון את התמיכה הדרושה לו כדי להיצמד לממברנה ולהשתלב במסלולי העברת האותות התאיים.

שם האזור	טווח שאריות	תפקיד מרכזי
G Domain	1-166	פעילות אנזימטית וקישור נוקליאוטידים
P-loop	10-14	קשירת הפוספט של ה-GTP
Switch I	30-40	ממשק קישור לאפקטורים (זיהוי מצב "on")

ויסות החלבון וקישור לאפקטורים	58-72	Switch II
עיגון ומיקום החלבון על ממברנת התא	167-188	HVR
אתר מודיפיקציה שומנית	185-188	CAAX Motif



EGFR


החלבון EGFR הוא קולטן טירוזין קינאז (Receptor Tyrosine Kinase) חוצה ממברנה, המתפקד כנקודת התחלה להעברת אותות גדילה מחוץ לתא אל תוכו. המבנה שלו מורכב משלושה אזורים עיקריים, כאשר האזור החוץ-תאי (Extracellular Region) משתרע משארית 25 ועד שארית 645. אזור זה מחלוק לארבעה דומיינים (I-IV), כאשר דומיינים I ו-III אחראים על קשירת הליגנד, ודומיין II מאפשר לשני קולטנים להיצמד זה לזה. לאחר קשירת הליגנד, הקולטן עובר שינוי מבני המעביר את האות דרך הדומיין הטרנס-ממברנלי (שאריות 646–668), המעגן את החלבון בתוך הממברנה ומקשר בין הסביבה החוץ-תאית לציטופלזמה. בצדו התוך-תאי של הקרום נמצא דומיין הטיירוזין קינאז (שאריות 713–973), המהווה את הלב התפקודי של החלבון. דומיין זה מתפקד כאנזים המזרז הוספת קבוצות פוספט לחלבונים אחרים ולעצמו. בתוך דומיין הקינאז קיימים אזורים חשובים במיוחד, כמו הקסל P (שאריות 741-750) האחראי על קשירת מולקולת ה-ATP. מוטציות רבות המזוהות עם מחלת הסרטן מתרחשות בדיוק

באזורים אלו. שינויים אלו בשאריות אלה גורמים לחלבון להיתקע במצב פעיל באופן קבוע, ובכך משדרים לתא פקודות חלוקה בלתי פוסקות.

החלק האחרון של החלבון הוא הקצה ה C טרמינלי המשתרע משארית 974 ועד סוף הרצף בשארית 1210. אזור זה הוא גמיש וארוך במיוחד, ותפקידו המרכזי הוא לשמש כלוח בקרה להעברת האותות. הוא כולל מספר שאריות טירוזין ספציפיות העוברות זרחון עצמי (Autophosphorylation) לאחר הפעלת הקולטן. שאריות אלו משמשות כאתרי עגינה לחלבוני העברת אותות במורד הזרם, אשר מזהים את הפוספט ומתחילים את שרשרת התגובות המובילה לחלוקת התא. מוטציות מסוימות המתרחשות בדומיין הקינאז משפיעות באופן אלוסטרי על הנגישות של הקצה ה C טרמינלי, ובכך מגבירות עוד יותר את עוצמת האות הסרטני המועבר לגרעין התא.

שם האזור	טווח שאריות	תפקיד מרכזי
Domain I (L1)	25-189	חלק מהמבנה החוץ-תאי היוצר את אתר הקישור הראשוני לליגנד
Domain II (CR1)	190-333	אחראי לחיבור בין שני קולטנים
Domain III (L2)	334-504	אחראי מרכזי בקשירת הליגנד. משתף פעולה עם דומיין I בשביל שתהיה קשירה יציבה
Domain IV (CR2)	505-645	הוא ודומיין II נשענים אחד על השני בשביל למנוע מהקולטן לזוז ללא הליגנד
Transmembrane (TM)	646-668	מקטע Helix החוצה את ממברנת התא ומעביר את האות פנימה.
Juxtamembrane (JM)	669-712	אחראי על הפעלת דומיין הקינאז הסמוך לו
Tyrosine Kinase Domain	713-973	הלב התפקודי של החלבון. הוא זה שמבצע את פעולת הזרחון. זהו מוקד המוטציות (Hotspot) העיקרי
P-loop	741-750	אתר בתוך הקינאז האחראי על קשירה ואחיזה של מולקולת ה-ATP לצורך הפקת אנרגיה

מתג בקרה פנימי הקובע את רצת הפעילות של האנזים. מוטציות כאן גורמות להפעלה קבועה	850-875	Activation Loop (A-loop)
זנב גמיש המכיל שאריות טירוזין שעוברות זרחון עצמי ומשמשות כנקודת עגינה לחלבונים בהמשך	974-1210	C-terminal Tail



הצטברות מוטציות באזורים ספציפיים (Hotspots)

פיזור המוטציות הסרטיניות לאורך רצף החלבון אינו מקרי. אף על פי שמוטציות ב-DNA קורות כל הזמן ובכל מקום באופן אקראי, מרבית המוטציות המתגלות אצל חולים מתרכזות באזורים ספציפיים הנקראים Hotspots. תופעה זו היא התוצאה של תהליך ברירה טבעית. תא שבו מתרחשת מוטציה באזור חסר חשיבות לא יזכה ליתרון הישרדותי וימות או יישאר תא תקין. לעומת זאת, מוטציות המתרחשות בתוך דומיינים פונקציונליים חשובים, האחראים על בקרת החלבון לדוגמה, עלולים לשבש את יכולות לבקר את עצמו. תאים אלו זוכים ליתרון על פני תאים אחרים, ומשתכפלים במהירות, והם אלה שמרכיבים את הגיול הסרטיני.

על פי המחקר Oncogenic mutant forms of EGFR: lessons in signal transduction and targets for cancer therapy, ממכון ויצמן, מוטציות ב-EGFR ממוקדות בעיקר בשני סוגי דומינים: דומינים אנזימטיים האחראים על העברת אותות, או דומינים רגולטוריים שתפקידם לעכב את החלבון. המחקר מפרט כי בסרטן ריאות, מוקד המוטציות העיקרי של EGFR ממוקד בדומיין הטירוזין קינאז התוך תאי, ובפרט באקסונים 18 עד 21. המוטציה הנקודתית השכיחה ביותר, R858L, מחליפה חומצת אמינו בעמדה 858. החלפה זו יוצרת מטען חשמלי חדש שכופה על התא להיות תמיד על מתג פעיל, ובכך התא מתרבה במהירות.

לסיכום, בחלבונים אונקוגניים יש בדרך"כ אזורים ספציפיים שבהם מתרחשות הרבה מוטציות. אזורים אלו, יימצאו בדרך"כ בדומינים פונקציונליים, שכן אלו האזורים שאחראים בין היתר על בקרת התא וגידולו.

בחירת הדומיינים הפונקציונליים בחלבונים

במהלך עבודתנו נתקלנו בבעיה. תחת ההגדרה הרשמית של דומיין פונקציונלי, בחלבון KRAS כמעט כל השאריות הן בתוך דומיינים פונקציונליים. עובדה זו גרמה לכך שרגרסיה לוגיסטית לא עובדת כראוי בחלבון זה, שכן בכדי שתעבוד כראוי, חובה לספק לה מספיק שאריות שאינן תחת דומיין פונקציונלי.

בעקבות כך, החלטנו לחקור את הנושא משני היבטים שונים:

1. על פי ההגדרה הרשמית של דומיין פונקציונלי, שהיא: דומיין פונקציונלי הוא אזור עצמאי שיכול להתקפל בעצמו ולעשות את תפקידו גם אם ינתקו אותו משאר החלבון.
תחת הגדרה זו, בחלבון KRAS יש רק 22 שאריות מתוך 188 שהן לא תחת דומיין פונקציונלי, ובחלבון EGFR יש 333 שאריות מתוך 1210 שהן לא תחת דומיין פונקציונלי.
2. על פי הפרשנות שלנו של דומיין פונקציונלי, שהיא: דומיין פונקציונלי הוא אזור בחלבון בעל תפקיד ספציפי, שאינו חייב להיות עצמאי.
תחת הגדרה זו, בחלבון KRAS יש 157 שאריות מתוך 188 שהן לא תחת דומיין פונקציונלי, ובחלבון EGFR יש 0 שאריות מתוך 1210 שהן לא תחת דומיין פונקציונלי.

ניתן לראות שיש ניגוד מוחלט בסיווג הדומיינים הפונקציונליים בין שני החלבונים בשני היבטים. תחת ההגדרה הרשמית של דומיין פונקציונלי, בחלבון KRAS אין מספיק שאריות תחת דומיינים פונקציונליים, ועל פי ההגדרה שלנו, בחלבון EGFR אין בכלל שאריות תחת דומיינים פונקציונליים. לכן, מעניין יהיה לראות אם יהיה הבדל משמעותי בין תוצאות הרגרסיה הלוגיסטית בשני היבטים הללו.

הדומיינים הפונקציונליים בכל אחד מהחלבונים תחת ההיבטים השונים

היבט 1: ההגדרה הרשמית

חלבון KRAS

שם האזור	טווח שאריות	תפקיד מרכזי
G Domain	1-166	פעילות אנזימטית וקישור נוקלאוטידים

חלבון EGFR

שם האזור	טווח שאריות	תפקיד מרכזי
Domain I (L1)	25-189	חלק מהמבנה החוץ-תאי היוצר את אתר הקישור הראשוני לליגנד
Domain II (CR1)	190-333	אחראי לחיבור בין שני קולטנים

אחראי מרכזי בקשירת הליגנד. משתף פעולה עם דומיין I בשביל שתהיה קשירה יציבה	334-504	Domain III (L2)
הוא ודומיין II נשענים אחד על השני בשביל למנוע מהקולטן לזוז ללא הליגנד	505-645	Domain IV (CR2)
הלב התפקודי של החלבון. הוא זה שמבצע את פעולת הזרחון. זהו מוקד המוטציות (Hotspot) העיקרי	713-973	Tyrosine Kinase Domain

היבט 2: ההגדרה שלנו

חלבון KRAS

שם האזור	טווח שאריות	תפקיד מרכזי
P-loop	10-14	קשירת הפוספט של ה-GTP
Switch I	30-40	ממשק קישור לאפקטורים (זיהוי מצב "on")
Switch II	58-72	ויסות החלבון וקישור לאפקטורים
CAAX Motif	185-188	אתר מודיפיקציה שומנית

חלבון EGFR

שם האזור	טווח שאריות	תפקיד מרכזי
Domain I (L1)	25-189	חלק מהמבנה החוץ-תאי היוצר את אתר הקישור הראשוני לליגנד
Domain II (CR1)	190-333	אחראי לחיבור בין שני קולטנים
Domain III (L2)	334-504	אחראי מרכזי בקשירת הליגנד. משתף פעולה עם דומיין I בשביל שתהיה קשירה יציבה
Domain IV (CR2)	505-645	הוא ודומיין II נשענים אחד על השני בשביל למנוע מהקולטן לזוז ללא הליגנד
Transmembrane (TM)	646-668	מקטע Helix החוצה את ממברנת התא ומעביר את האות פנימה.

אחראי על הפעלת דומיין הקינאז הסמוך לו	669-712	Juxtamembrane (JM)
הלב התפקודי של החלבון. הוא זה שמבצע את פעולת הזרחון. זהו מוקד המוטציות (Hotspot) העיקרי	713-973	Tyrosine Kinase Domain
אתר בתוך הקינאז האחראי על קשירה ואחיזה של מולקולת ה-ATP לצורך הפקת אנרגיה	741-750	P-loop
מתג בקרה פנימי הקובע את רצת הפעילות של האנזים. מוטציות כאן גורמות להפעלה קבועה	850-875	Activation Loop (A-loop)
זנב גמיש המכיל שאריות טירוזין שעוברות זרחון עצמי ומשמשות כנקודת עגינה לחלבונים בהמשך	974-1210	C-terminal Tail

אנליזה

לשם בדיקת שאלת המחקר שלנו, כתבנו תוכנית שנכתבה כולה בשפת פייתון (python), שבסופה מוצאת האם בדומיינים פונקציונליים בחלבונים EGFR ו-KRAS יש סבירות גבוהה יותר להיווצרות מוטציות מבדומיינים לא פונקציונליים.

בפרק זה, ננתח את כל הקבצים והאלגוריתמים המרכזיים, ונראה איך הם מתחברים ביחד.

קבצי הפרויקט

עץ הקבצים

```
cancer_mutations_in_proteins/
├── data/
│   ├── EGFR.fasta.txt
│   ├── EGFR_mutations.tsv
│   ├── KRAS.fasta.txt
│   └── KRAS_mutations.tsv
├── documents/
│   ├── הצעת המחקר.docx
│   ├── הערכת הצעת מחקר - איל ושקד.docx
│   ├── תוצאות והסקות.docx
│   └── index.docx
├── results/
│   ├── logistic_regression.txt
│   ├── mutation_analysis_plot.png
│   ├── protein_mutation_data.csv
│   └── results.txt
├── scripts/
│   ├── config_data.py
│   ├── logistic_regression.py
│   ├── main.py
│   └── processor.py
├── domain_mutation_analysis.py
├── logistic_regression_analysis.png
├── mutation_analysis_plot.png
└── README.md
```

הסבר על כל קובץ

Data/

EGFR.fasta.txt – מכיל את רצף החלבון EGFR.

EGFR.mutations.tsv – מכיל את נתוני המוטציות של EGFR.

KRAS.fasta.txt – מכיל את רצף החלבון KRAS.

KRAS.mutations.tsv – מכיל את נתוני המוטציות של KRAS.

Results/

Logistic_regression.txt – תוצאות הרגרסיה הלוגיסטית.

Protein_mutation_data.csv – טבלת נתונים שהרגרסיה משתמשת בה. לכל עמדה בחלבון, היא

אומרת האם הוא נמצא בתוך דומיין פונקציונלי, האם הוא עבר מוטציה לפחות פעם אחת, וכמה

פעמים בסה"כ הוא עבר מוטציה.

Results.txt – ספירת מוטציות לפי דומיינים לשני החלבונים.

Scripts/

Config_data.py – מגדיר את מילוני הדומיינים הפונקציונליים של שני החלבונים, ואת נתיבי קבצי הפלט.

Logistic_regression.py – מכיל פונקציה שמריצה את הרגרסיה, מדפיסה את התוצאות לטרמינל ולקובץ results/logistic_regression.txt.

Main.py – מפעיל את כל שלבי העיבוד והתוצאות לשני החלבונים. זהו הקובץ הראשי של התוכנית.

Processor.py – מכיל פונקציות שמעבדות את רצפי החלבונים, ממפות את המוטציות ועוד. קבצי בסיס

domain_mutation_analysis.py – מדפיס סיכום שכולל מידע כמו כמה חומצות אמינו בכל דומיין וכמה מהן עבור מוטציה וכמה חומצות אמינו לא בתוך דומיין וכמה מהן עבור מוטציה.

האלגוריתם הכללי של התוכנית

התוכנית מחולקת ל3 חלקים מרכזיים:

- קליטת הנתונים ושמירתם. כגון: רצפי החלבונים, עיבוד המוטציות.
- יצירת קובץ ייעודי בו יהיה סיכום על כל אחד מהשאריות בכל אחד מהחלבונים. הסיכום יכול: מיקום השארית, האם הוא עבר מוטציה וכמה מוטציות הוא עבר.
- חישוב הרגרסיה לכל אחד מהחלבונים בנפרד ולשניהם יחדיו.

מודל הרגרסיה הלוגיסטית

המודל החישובי שאנחנו בחרנו לפרויקט זה הוא רגרסיה לוגיסטית. בחרנו בו מכיוון ששאלת המחקר שלנו בוחנת משתנה בינארי(האם שארית מסוימת בחלבון עברה מוטציה או לא. 1 או 0). רגרסיה לוגיסטית היא הכלי המדויק ביותר לניבוי ההסתברות של אירוע כזה. מעבר לכך, הבחירה ברגרסיה לוגיסטית חשובה לצורך נרמול הנתונים. דומיינים ארוכים יותר מכילים מספר רב יותר של שאריות, ולכן קיים סיכוי גבוה יותר שיופיעו בהם מוטציות באקראי. המודל מאפשר לנו לבחון את עוצמת הקשר באמצעות odds ratio. ככה, ניתן למצוא האם יש מובהקות סטטיסטית.

פונקציות מרכזיות בתוכנית

הפונקציה הראשית, בקובץ main.py:

```
if __name__ == "__main__":
    # עובר DataFrame יצירת
    with open(DATA_PATHS["EGFR_FASTA"], "r") as f_seq,
    open(DATA_PATHS["EGFR_MUTATIONS"], "r") as f_mut:
```



```

egfr_len = get_protein_sequence_length(f_seq)
egfr_mut_list = get_list_of_all_protein_changes(f_mut)
egfr_indices = get_mutation_indices(egfr_mut_list)

df_egfr = build_regression_dataframe("EGFR", egfr_len,
CHOSEN_EGFR_DOMAINS_DICTIONARY, egfr_indices)

# עבור DataFrame יצירת KRAS
with open(DATA_PATHS["KRAS_FASTA"], "r") as f_seq,
open(DATA_PATHS["KRAS_MUTATIONS"], "r") as f_mut:
    kras_len = get_protein_sequence_length(f_seq)
    kras_mut_list = get_list_of_all_protein_changes(f_mut)
    kras_indices = get_mutation_indices(kras_mut_list)

df_kras = build_regression_dataframe("KRAS", kras_len,
CHOSEN_KRAS_DOMAINS_DICTIONARY, kras_indices)

# אחד DataFrame ל-EGFR ו-KRAS DataFrames איחוד ה
final_df = pd.concat([df_egfr, df_kras])
# המרה לקובץ CSV
final_df.to_csv("results/protein_mutation_data.csv", index=False)

print("Success! Data table created.")

# יוצרת סיכום עבור כל חלבון של כמות המוטציות בכל דומיין עם טווחי הדומיין
# וכמות העמדות וסכום המוטציות שלא נמצאים בדומיין כלשהו
save_domain_mutations_report(df_egfr, df_kras,
CHOSEN_EGFR_DOMAINS_DICTIONARY, CHOSEN_KRAS_DOMAINS_DICTIONARY)

# איפוס קובץ התוצאות של הרגרסיה הלוגיסטית
open('results/logistic_regression_results.txt', 'w').close()

# הרצת רגרסיה לוגיסטית על כל הנתונים המשולבים ובנוסף על כל חלבון בנפרד
run_logistic_regression(final_df, analysis_name="Combined (EGFR & KRAS)")
run_logistic_regression(df_egfr, analysis_name="EGFR Only")
run_logistic_regression(df_kras, analysis_name="KRAS Only")

```

הסבר: פונקציה זו מנתחת כל חלבון, סוכמת לו את המוטציות וגם מבצעת על כל חלבון רגרסיה. לבסוף, היא תדפיס לטרמינל את תוצאות הרגרסיה, ובנוסף גם לקובץ ייעודי.

הפונקציה להפעלת הרגרסיה הלוגיסטית:

```

def run_logistic_regression(df, analysis_name="Combined"):
    print(f"\n" + "="*40)
    print(f"Running Logistic Regression for: {analysis_name}")
    print("="*40)
    # הוא המשתנה 'has_mutation' והמשתנה (X) היא המשתנה הבלתי תלוי 'is_in_domain' המשתנה (y) התלוי
    X = df[['is_in_domain']]

```

```

y = df['has_mutation']
# חלוקת הנתונים לאימון ובדיקה (80% לאימון, 20% לבדיקה) תוך שמירה על פרופורציות המוטציות (stratify=y).
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42, stratify=y)
# אימון המודל
model = LogisticRegression(class_weight='balanced')
model.fit(X_train, y_train)

intercept = model.intercept_[0]
coef = model.coef_[0][0]
odds_ratio = np.exp(coef)

# p-value via statsmodels Logit (MLE, no regularization)
X_sm = sm.add_constant(X)
sm_result = sm.Logit(y, X_sm).fit(dis=0)
p_value = sm_result.pvalues['is_in_domain']

print(f"Intercept: {intercept:.4f}")
print(f"Coefficient (is_in_domain): {coef:.4f}")
print(f'Odds Ratio: {odds_ratio:.4f}')
print(f"P-value (is_in_domain): {p_value:.4e}")

y_pred = model.predict(X_test)
report = classification_report(y_test, y_pred)
print(report)

with open('results/logistic_regression_results.txt', 'a') as f:
    f.write(f"=====\n")
    f.write(f"Analysis: {analysis_name}\n")
    f.write(f"=====\n")
    f.write(f"Intercept: {intercept:.4f}\n")
    f.write(f"Coefficient (is_in_domain): {coef:.4f}\n")
    f.write(f'Odds Ratio: {odds_ratio:.4f}\n')
    f.write(f"P-value (is_in_domain): {p_value:.4e}\n\n")
    f.write("Classification Report:\n")
    f.write(report)
    f.write("\n\n")

```

הסבר: פונקציה זו מבצעת ניתוח סטטיסטי באמצעות רגרסיה לוגיסטית כדי לבדוק האם קיים קשר בין המיקום של עמדה בחלבון (האם היא נמצאת בתוך דומיין פונקציונלי או מחוצה לו) לבין הסיכוי שתתרחש בה מוטציה.

פונקציה לבניית טבלת הנתונים לרגרסיה:

```

def build_regression_dataframe(protein_name, seq_len, domains_dict,
mutation_indices):
    """

```

```

. יוצר טבלה שבה כל שורה היא עמדה בחלבון (1 עד אורך החלבון)
העמודות כוללות:
protein: שם החלבון (EGFR או KRAS)
pos: מיקום העמדה
is_in_domain: האם העמדה בתוך דומיין (0 או 1)
has_mutation: האם יש מוטציה בעמדה (0 או 1)
mutation_count: כמה מוטציות יש בעמדה
"""

# [12, 858] לרשימה אחת שטוחה [858], [הופך רשימת רשימות [12]]
flat_mutations = [idx for sublist in mutation_indices for idx in sublist]

rows = []
for pos in range(1, seq_len + 1):
    # האם העמדה בתוך דומיין כלשהו? (0 או 1)
    is_in_domain = 0
    for (start, end) in domains_dict.keys():
        if start <= pos <= end:
            is_in_domain = 1
            break

    # האם יש מוטציה בעמדה הזו? (0 או 1)
    has_mutation = 1 if pos in flat_mutations else 0

    # כמה מוטציות יש בעמדה הזו?
    mut_count = flat_mutations.count(pos)

    rows.append({
        'protein': protein_name,
        'pos': pos,
        'is_in_domain': is_in_domain,
        'has_mutation': has_mutation,
        'mutation_count': mut_count
    })

return pd.DataFrame(rows)

```

הסבר: פונקציה זו אחראית על שלב עיבוד הנתונים והכנתם עבור מודל הרגרסיה. היא הופכת את המידע על החלבון (אורכו, המוטציות שבו והדומיינים שלו) לטבלה שבה כל שורה מייצגת עמדה (שארית) בודדת לאורך החלבון, החל מעמדה 1 ועד העמדה האחרונה. לטבלה מורכבת מהעמודות הבאות:

1. שם החלבון
2. מספר המיקום הפיזי של השארית בחלבון
3. האם הוא בתוך דומיין
4. האם הוא עבר מוטציה
5. כמה מוטציות הוא עבר

הערכת שגיאות צפויות

בתוצאות הרגרסיה אנחנו צופים p value גבוה מאוד בחלק מהמקרים. אנחנו צופים זאת מכיוון שבכמה מהגרסות של הדומיינים של החלבונים, אין כמעט בכלל שאריות שהן מחוץ לדומיין. כתוצאה מכך, למודל לא יהיה כמעט מידע על שאריות מחוץ לדומיין, ולכך $odds\ ratio$ יהיו לא נכון זה p value קרוב מאוד ל-1.

תוצאות הרצת התוכנית

כפי שפורט בפרקים הקודמים, ובפרט בפרק "בחירת הדומיינים הפונקציונליים בחלבונים", אנחנו מריצים את התוכנית פעמיים. כל פעם עם טווחי דומיינים פונקציונליים שונים של שני החלבונים. בהרצה הראשונה, שהיא לפי ההגדרה הרשמית של דומיין פונקציונלי, נשתמש במילונים הבאים:

```
KRAS_DOMAINS_BY_DEFINITION = {
    (1, 166): "G Domain",
}

EGFR_DOMAINS_BY_DEFINITION = {
    (25, 189): "Domain I (Ligand binding)",
    (190, 333): "Domain II (Dimerization interface)",
    (334, 504): "Domain III (Ligand binding)",
    (505, 645): "Domain IV (CR2)",
    (713, 973): "Tyrosine Kinase Domain",
}
```

בהרצה השנייה, שהיא לפי ההגדרה שלנו של דומיין פונקציונלי, נשתמש במילונים הבאים:

```
KRAS_ALL_REGIONS_WITH_FUNCTION = {
    (10, 14): "P-loop",
    (30, 40): "Switch I",
    (58, 72): "Switch II",
    (185, 188): "CAAX motif"
}

EGFR_ALL_REGIONS_WITH_FUNCTION = {
    (25, 189): "Domain I (L1)",
    (190, 333): "Domain II (CR1)",
    (334, 504): "Domain III (L2)",
    (505, 645): "Domain IV (CR2)",
    (646, 668): "Transmembrane (TM)",
    (669, 712): "Juxtamembrane (JM)",
    (713, 973): "Tyrosine Kinase Domain",
    (741, 750): "P-loop (Nucleotide Binding)",
    (850, 875): "Activation Loop (A-loop)",
    (974, 1210): "C-terminal Tail"
}
```

תוצאות ההרצה לפי ההגדרה הרשמית של דומיין פונקציונלי

תוצאות הרגרסיה (logistic_regression.txt):

```
=====
Analysis: Combined (EGFR & KRAS)
=====
Intercept: -0.5483
```

Coefficient (is_in_domain): 0.6752
Odds Ratio: 1.9645
P-value (is_in_domain): 3.4733e-02

Classification Report:

	precision	recall	f1-score	support
0	1.00	0.30	0.46	271
1	0.05	1.00	0.09	9
accuracy			0.33	280
macro avg	0.52	0.65	0.28	280
weighted avg	0.97	0.33	0.45	280

=====

Analysis: EGFR Only

=====

Intercept: -0.8911
Coefficient (is_in_domain): 1.0773
Odds Ratio: 2.9367
P-value (is_in_domain): 7.8468e-02

Classification Report:

	precision	recall	f1-score	support
0	0.98	0.34	0.50	235
1	0.03	0.71	0.06	7
accuracy			0.35	242
macro avg	0.50	0.53	0.28	242
weighted avg	0.95	0.35	0.49	242

=====

Analysis: KRAS Only

=====

Intercept: -1.5189
Coefficient (is_in_domain): 1.5993
Odds Ratio: 4.9498
P-value (is_in_domain): 9.9944e-01

Classification Report:

	precision	recall	f1-score	support
0	1.00	0.17	0.29	36
1	0.06	1.00	0.12	2
accuracy			0.21	38

macro avg	0.53	0.58	0.20	38
weighted avg	0.95	0.21	0.28	38

מיפוי המוטציות:(domain_mutations.txt):

MUTATION COUNT BY DOMAIN

=====

EGFR PROTEIN

Domain Name	Range	Mutations
Domain I (Ligand binding)	25-189	2
Domain II (Dimerization interface)	190-333	3
Domain III (Ligand binding)	334-504	4
Domain IV (CR2)	505-645	2
Tyrosine Kinase Domain	713-973	87

amount_of_amino_acids_not_in_domain = 328
 mutations_not_in_domain = 9

=====

KRAS PROTEIN

Domain Name	Range	Mutations
G Domain	1-166	163

amount_of_amino_acids_not_in_domain = 23
 mutations_not_in_domain = 0

=====

(חשוב לציין כי הרגרסיה מתייחסת לכל שארית רק אם היא עברה פעם אחת לפחות מוטציה או לא. זאת אומרת, שאם אותה השארית עברה כמה פעמים מוטציה, היא עדיין תיחשב כאילו עברה מוטציה אחת. בהשוואה הנ"ל כשכתוב את כמות המוטציות לכל דומיין, כתוב את סך המוטציות שעברו כל השאריות, ולא את כמות השאריות שעברו מוטציה. לכן, אם מנסים לחשב ידנית את ה-odds ratio, אין להשתמש בנתונים אלה, אלא לספור בעצמנו את הנתונים מהטבלה (protein_domain_data).

ניתוח התוצאות

בהרצה המשולבת של שני החלבונים התקבל קשר מובהק בין מוטציות לדומיינים פונקציונליים בחלבונים EGFR ו-KRAS.

ה-Odds Ratio הוא 1.9645. ז"א, שבדומיינים פונקציונליים יש סיכוי גבוה פי כמעט 2 להימצאות מוטציות מאשר באזורים אחרים. בנוסף, ערך ה-P value הינו 0.034, שהוא נמוך מסף המובהקות המקובל (0.05). עובדה זו מאשרת כי קיים קשר בין היותו של מיקום בחלבון בדומיין פונקציונלי לבין נטייתו לקבל מוטציה.

בניתוח האישי של כל חלבון, אנחנו רואים שבEGFR יש odds ratio של 2.9, ו-p value של כמעט 0.05 (0.07). זה מעיד שתחת ההגדרה הרשמית של דומיינים פונקציונליים, יש קשר מובהק בחלבון EGFR.

בחלבון KRAS אנחנו מקבל odds ratio גדול אף יותר, של כמעט 5! עם זאת, חשוב לראות שה-p value הוא 0.99. ז"א, שאין מספיק נתונים להראות נטייה כלשהי בחלבון זה. זה קורה ככל הנראה בגלל שיש רק 23 שאריות שלא תחת דומיין פונקציונלי, ולכן אין למודל מספיק נתונים.

תוצאות ההרצה לפי ההגדרה שלנו של דומיין פונקציונלי

תוצאות הרגרסיה (logistic_regression.txt):

```
=====
Analysis: Combined (EGFR & KRAS)
=====
Intercept: -0.0967
Coefficient (is_in_domain): 0.1094
Odds Ratio: 1.1156
P-value (is_in_domain): 7.4172e-01

Classification Report:

```

	precision	recall	f1-score	support
0	0.98	0.15	0.26	271
1	0.03	0.89	0.06	9
accuracy			0.17	280
macro avg	0.50	0.52	0.16	280
weighted avg	0.95	0.17	0.25	280

```
=====
Analysis: EGFR Only
=====
Intercept: 0.5015
Coefficient (is_in_domain): -0.5152
Odds Ratio: 0.5974
P-value (is_in_domain): 7.2996e-01

Classification Report:

```

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

0	0.97	0.98	0.97	235
1	0.00	0.00	0.00	7
accuracy			0.95	242
macro avg	0.49	0.49	0.49	242
weighted avg	0.94	0.95	0.95	242

=====

Analysis: KRAS Only

=====

Intercept: -0.5883

Coefficient (is_in_domain): 1.6575

Odds Ratio: 5.2463

P-value (is_in_domain): 8.8454e-03

Classification Report:

	precision	recall	f1-score	support
0	0.97	0.83	0.90	36
1	0.14	0.50	0.22	2
accuracy			0.82	38
macro avg	0.56	0.67	0.56	38
weighted avg	0.92	0.82	0.86	38

מיפוי המוטציות:(domain_mutations.txt):

MUTATION COUNT BY DOMAIN

=====

EGFR PROTEIN

Domain Name	Range	Mutations
Domain I (L1)	25-189	2
Domain II (CR1)	190-333	3
Domain III (L2)	334-504	4
Domain IV (CR2)	505-645	2
Transmembrane (TM)	646-668	0
Juxtamembrane (JM)	669-712	6
Tyrosine Kinase Domain	713-973	87
P-loop (Nucleotide Binding)	741-750	38
Activation Loop (A-loop)	850-875	25
C-terminal Tail	974-1210	2

```

amount_of_amino_acids_not_in_domain = 24
mutations_not_in_domain = 1

=====

KRAS PROTEIN

-----
Domain Name                Range                Mutations
-----
P-loop                     10-14              153
Switch I                   30-40              1
Switch II                  58-72              3
CAAX motif                 185-188            0

amount_of_amino_acids_not_in_domain = 154
mutations_not_in_domain = 6

=====

```

(חשוב לציין כי הרגרסיה מתייחסת לכל שארית רק אם היא עברה פעם אחת לפחות מוטציה או לא. זאת אומרת, שאם אותה השארית עברה כמה פעמים מוטציה, היא עדיין תיחשב כאילו עברה מוטציה אחת. בהשוואה הנ"ל כשכתוב את כמות המוטציות לכל דומיין, כתוב את סך המוטציות שעברו כל השאריות, ולא את כמות השאריות שעברו מוטציה. לכן, אם מנסים לחשב ידנית את ה-odds ratio, אין להשתמש בנתונים אלה, אלא לספור בעצמנו את הנתונים מהטבלה (protein_domain_data).

ניתוח התוצאות

בהרצה זו, התוצאות שהתקבלו היו שונות משמעותית מבהרצה הראשונה. בבדיקה המשולבת של שני החלבונים, ערך ה-P value הוא 0.741. זהו ערך גבוה מאוד. המשמעות היא שהתוצאה אינה מובהקת בכלל. ז"א, אין הבדל הניתן להוכחה בין דומיינים פונקציונליים לבין שאר החלבון.

ה-Odds Ratio אמנם גדול מ-1 ושווה ל-1.115, אך זאת עדיין עלייה זניחה מאוד (11%), ובהתחשב ב-P value, איך לה באמת תוקף.

בבדיקות האישיות של כל חלבון, התקבלה תוצאה הפוכה מבהרצה הראשונה. בחלבון EGFR התקבל odds ratio של 0.59. פחות מ-1. ז"א שלא רק שאין יתרון לדומיינים פונקציונליים, אלא שיש דווקא חסרון. אנחנו רואים שה-P value גבוה מאוד ועומד על 0.73. בגלל שכל החלבון כמעט מסווג כדומיין פונקציונלי, אין למודל כמעט ממה ללמוד. בחלבון KRAS לעומת התוצאות מעידות על מובהקות ממש גדולה. ה-odds ratio עומד על 5.2 ו-P value אפסי (0.008). כל אלו מעידים על קשר מובהק בין דומיין פונקציונלי להימצאות מוטציה בו.

אישוש

בפרק זה נוודא שהתוצאות שהתקבלו הן אכן התוצאות הנכונות, ושלא התרחשה איזושהי שגיאה בקוד או בחישובים.

נתחיל ממקורות הנתונים. את שני המסמכים שמאגדים את מיקומי המוטציות הסרטניות בכל אחד משני החלבונים לקחנו מהאתר CbioPortal. הסתכלנו על 10 מוטציות במיקומים שונים בכל אחד משני הקבצים, ווידנו שהם נספרו בקובץ protein_mutation_data, שמאגד את כל המוטציות בכל אחד מהשאריות, ואכן כל אחד מהמוטציות הייתה שם. בנוסף, השונו את כמות המוטציות שיש בקבצים, לבין כמות המוטציות שנספרו בפועל, והתוצאה הייתה זהה. מבחינת מיקומי הדומיינים, השתמשנו בנתונים מכמה מחקרים רשמיים, ולכן ניתן להסיק שגם הם נכונים. לפיכך, יש להסיק שמיפוי הדומיינים והמוטציות עובד כראוי.

כעת נדבר על חישוב הרגרסיה. השתמשנו ב2 גרסאות לדומיינים שונים אצל כל אחד מהחלבונים, ולכן היו סה"כ 6 רגרסיות שונות:

1. רגרסיה משותפת על EGFR וKRAS תחת ההגדרה הרשמית של דומיין פונקציונלי.
 2. רגרסיה על EGFR תחת ההגדרה הרשמית של דומיין פונקציונלי.
 3. רגרסיה על KRAS תחת ההגדרה הרשמית של דומיין פונקציונלי.
 4. רגרסיה משותפת על EGFR וKRAS תחת ההגדרה שלנו של דומיין פונקציונלי.
 5. רגרסיה על EGFR תחת ההגדרה שלנו של דומיין פונקציונלי.
 6. רגרסיה על KRAS תחת ההגדרה שלנו של דומיין פונקציונלי.
- אנחנו בדקנו וחישבנו לבדנו שכל 6 הרגרסיות נכונות, אך לצורך הדוגמא נביא חישוב אחד, שביצענו לבדיקת הרגרסיה על EGFR תחת ההגדרה שלנו של דומיין פונקציונלי (מספר 5).

חשוב לציין כי בדיקת הרגרסיה היא בעצם לוודא שה-odds ratio נכון. ניתן לעשות זאת באמצעות בחינת הנתונים והשוואה ידנית שלנו אל מול התוצאה. בהרצה הנ"ל של חלבון EGFR התקבלו התוצאות הבאות:

```
Coefficient (is_in_domain): -0.5152
Odds Ratio: 0.5974
P-value (is_in_domain): 7.2996e-01
```

נתונים על כמות המוטציות בתוך דומיין ומחוץ דומיין:

בתוך דומיין:

כמות שאריות = 1186

כמות שאריות שעברו מוטציה = 35

מחוץ לדומיין:

כמות שאריות = 24

כמות שאריות שעברו מוטציה = 1

אנחנו נדרשים לבדוד את מספר השאריות שלא עברו מוטציה בכל קבוצה. בתוך הדומיין, נחסיר 35 מתוך 1186 ונקבל 1151 שאריות שלא עברו מוטציה. מחוץ לדומיין, נחסיר מוטציה אחת ונקבל 23 שאריות שלא עברו מוטציה.

כעת, נחשב את הסיכויים עבור כל קבוצה בנפרד. עבור השאריות שנמצאות בתוך הדומיין, הסיכוי לעבור מוטציה הוא 35 חלקי 1151, מה שנותן לנו ערך של כ-0.0304. עבור השאריות שנמצאות מחוץ לדומיין, הסיכוי הוא מוטציה אחת חלקי 23 שאריות שלא עברו מוטציה, מה שנותן לנו ערך של כ-0.0435.

בחלק האחרון, אנחנו נחלק את הסיכוי לעבור מוטציה בתוך דומיין בסיכוי לעבור מוטציה מחוץ לדומיין: $0.0435 / 0.0304 = 0.699$.

התוצאה שקיבלנו אינה זהה בדיוק לתוצאה של המחשב (0.59), אך זאת ככל הנראה בגלל צורת חישוב מעט שונה שהמודל עושה, ככל הנראה בגלל כמות המידע הקטנה מאוד שיש לנו. עם זאת, התוצאה שקיבלנו גם היא קטנה משמעותית מ-1, מה שמאשר שהתוצאה שהתקבלה תקינה.

לסיכום, וידאנו שהנתונים שאנחנו משתמשים בהם נכונים, וידאנו שקליטת הנתונים ועיבודם נכונים, וידאנו שחישוב הרגרסיה נכון. לפיכך, אנחנו מסיקים שהתוצאות שהתקבלו מהימנות.

דיון בתוצאות

התוצאות הסופיות שקיבלנו היו מעניינות ומפתיעות מאוד משציפינו בהתחלה. אמנם, השערתנו הראשונית כי קיימת נטייה למוטציות להיווצר בדומיינים פונקציונליים התגלתה כנכונה, אך האמת מסובכת יותר מזה.

תחת ההגדרה הרשמית של דומיין פונקציונלי, בחלבון EGFR אכן קיימת נטייה חזקה לדומיינים פונקציונליים. אך בחלבון KRAS, בשל מיעוט השאריות שמחוץ לדומיין, לא התקבלו תוצאות עם מובהקות סטטיסטית.

תחת הגדרתנו של דומיין פונקציונלי, בחלבון EGFR לא נמצאה נטייה לדומיינים פונקציונליים, אך דווקא ב-KRAS כן.

התוצאות שקיבלנו אכן מבלבלות, והן נגרמות ממיעוט ב-DATA על החלבונים. אך אם אנחנו נתייחס לאורכי הדומיינים בכל חלבון, אנחנו נבין שככל שמיקדנו את טווח הדומיין הפונקציונלי לחלקים הפעילים ביותר, כך המובהקות הסטטיסטית גדלה. למסקנה זו יש גם תימוכין במאמר: "Structure-Based View of Epidermal Growth Factor Receptor Regulation". על פי מאמר זה, טווח המיקומים עם הכי הרבה מוטציות הוא דומיין האירוזין קינאז, המשתרע בין השאריות 713-973. בתוך טווח ממוקד זה, המאמר מבציע על תתי אזורים המרכזים את מרבית המוטציות האונקוגניות, ובראשם ה-P loop, האחראי על קשירת ה-ATP, המתפקד כמתג בקרה פנימי.

התאמה זו בין המחקרים לתוצאות הקוד שלנו מסבירה את התוצאות. כאשר הגדרנו את כל חלבון KRAS כדומיין פונקציונלי אחד גדול, המודל לא הצליח לזהות נטייה כלשהי. מנגד, כאשר השתמשנו בהגדרה הרשמית ופירקנו את החלבון לאזורים מצומצמים יותר, קיבלנו נטייה מובהקת.

לסיכום, התוצאות מוכיחות כי הברירה הטבעית של הגידול הסרטני אינה משמרת מוטציות באופן אקראי, אלא פועלת בצורה ממוקדת באופן ספציפי בנקודות האחראיות ישירות על הפעלת הקולטן וכיבוי מנגנוני הבקרה העצמית שלו, ובכלל בדומיינים פונקציונליים.

סיכום

לאורך העבודה העמקנו את הבנתנו במספר מושגים בביולוגיה כמו סוגי דומיינים שונים, שאריות, אונקוגן ועוד רבים. בנוסף, למדנו בצורה מעמיקה את המבנה והתפקוד של שני חלבונים חשובים מאוד בחקר הסרטן: EGFR ו-KRAS. כמו כן, גילינו שהחיבור בין התיאוריה למציאות בשטח הוא מורכב. למשל, כשרצינו להגדיר את הדומיינים הפונקציונליים, נחשפנו לכך שההגדרה הרשמית של דומיין פונקציונלי לא עבדה כראוי לאחד החלבונים. כתוצאה מכך, יצרנו כמה נקודות מבט שונות לאותה השאלה. המעבר הזה בין נקודות המבט השונות לימד אותנו על

לצד הביולוגי, רכשנו שיטות תכנותיות ומתמטיות מתקדמות שלא הכרנו קודם לכן. שיפרנו את היכולת שלנו לקחת קבצי גנים מבולגנים בפורמט FASTA ולנקות אותם מתווים מיותרים. למדנו לעבוד עם מאגרי נתונים ענקיים. למדנו לנהל ולסדר את כל המידע המורכב בטבלאות. הכלי המשמעותי ביותר שרכשנו הוא הרגרסיה הלוגיסטית שהוא כלי סטטיסטי שאפשר לנו לבחון את הסיכוי להופעת מוטציה באזור מסוים תוך התחשבות באורך שלו, ובכך נמנעה ההטיה הסטטיסטית שבה דומיין ארוך יקבל יותר מוטציות באקראי רק בגלל הגודל שלו. חלקנו הגענו בלי ידע מוקדם בכלל בסטטיסטיקה ובייחוד ברגרסיה, כך שלמדנו המון. לאחר ניתוח מעמיק של התוצאות ומחקרים ומאמרים בנושא, הגענו למסקנה שמוטציות סרטניות אינן מתפלגות בצורה אקראית לאורך החלבון. הגידול הסרטני מציג מעין אבולוציה, שבה נשמרות דווקא המוטציות שמתרכזות באזורים האחראים לבקרת החלבון והפעלתו.

מבחינת הצעות לשיפור, ניתן להציע כמה דברים לשפר: ראשית, ניתן להרחיב את המחקר לחלבונים אונקוגניים נוספים (כגון HER2 ו-NRAS), ולבדוק אם גם בחלבונים אלה תהיה נטייה למוטציות להיווצר בדומיינים פונקציונליים. אם כך יהיה הדבר, זה יחזק משמעותית את המסקנה שלנו.

שנית, כדאי יהיה לשלב בתוך מודל הרגרסיה משקולת סטטיסטית המתחשבת בתדירות המופעים של כל מוטציה באוכלוסיית החולים מתוך מאגר המוטציות, ולא רק לסמן באופן בינארי אם המוטציה קיימת או לא.

שנית, כדאי יהיה לגרום למודל הרגרסיה להתחשב בכמות המוטציות שנוצרו בכל חומצת אמינו, ולא רק אם היא עברה פעם אחת מוטציה או לא. כך, המודל יוכל להבחין בין מיקומים אקראיים שבהם תדירות המוטציות נמוכה, לבין Hotspots בעלות חשיבות גבוהה.

ביבליוגרפיה

Logistic regression - <https://youtu.be/yIYKR4sgzI8?si=934UdgRSUNDIXlyC>

מידע על KRAS

[/https://pmc.ncbi.nlm.nih.gov/articles/PMC6965201](https://pmc.ncbi.nlm.nih.gov/articles/PMC6965201)

מידע על EGFR

[/https://pmc.ncbi.nlm.nih.gov/articles/PMC2745238](https://pmc.ncbi.nlm.nih.gov/articles/PMC2745238)

מידע נוסף על EGFR

https://www.uniprot.org/uniprotkb/P00533/entry#family_and_domains

מידע על כל אזורי hotspot של EGFR

<https://1lib.sk/book/8vEr5dL9PB/structurebased-view-of-epidermal-growth-factor-receptor-regulation.html>

הורדת קבצי המוטציות של החלבונים EGFR ו-KRAS

https://www.cbioportal.org/results/mutations?cancer_study_list=luad_tcga_pan_can_atlas_2018&Z_SCORE_THRESHOLD=2.0&RPPA_SCORE_THRESHOLD=2.0&profileFilter=mutations%2Cstructural_variants%2Cgistic&case_set_id=luad_tcga_pan_can_atlas_2018_cnaseq&gene_list=EGFR%2520KRAS&geneset_list=%20&tab_index=tab_visualize&Action=Submit&mutations_gene=EGFR

Oncogenic mutant forms of EGFR: lessons in signal transduction and targets for cancer therapy.

<https://pmc.ncbi.nlm.nih.gov/articles/PMC2892754/>

(אגב, זה של חוקרים ממכון ויצמן!)

נספחים

הוראות להפעלת התוכנית

תחת התיקייה cancer_mutations_in_proteins נמצאים כל קבצי הפרויקט.

בכדי להריץ את הפרויקט, יש לנווט לקובץ main.py שתחת התיקייה scripts ולהריצו.

חלק מ-main.py:

```
scripts > main.py > ...
1  import pandas as pd
2  from config_data import KRAS_DOMAINS_BY_DEFINITION, KRAS_ALL_REGIONS_WITH_FUNCTION, EGFR DOM
3  from logistic_regression import run_logistic_regression
4  from processor import (
5      get_protein_sequence_length,
6      get_list_of_all_protein_changes,
7      get_mutation_indices,
8      build_regression_dataframe,
9      save_domain_mutations_report
10 )
11
12 '''
13 For KRAS choose:
14 KRAS_DOMAINS_BY_DEFINITION OR KRAS_ALL_REGIONS_WITH_FUNCTION
15
16 For EGFR choose:
17 EGFR_DOMAINS_BY_DEFINITION OR EGFR_ALL_REGIONS_WITH_FUNCTION
18 '''
19
20 CHOSEN_KRAS_DOMAINS_DICTIONARY = KRAS_ALL_REGIONS_WITH_FUNCTION
21 CHOSEN_EGFR_DOMAINS_DICTIONARY = EGFR_ALL_REGIONS_WITH_FUNCTION
22
23
```

פקודות bash:

```
cd cancer_mutations_in_proteins
```

```
cd scripts
```

```
python main.py
```

לאחר הרצת התוכנית, יודפס בטרמינל תוצאות הרגרסיה לכל אחד מהחלבונים. בנוסף, תוצאות

הרגרסיה יודפסו גם בקובץ ייעודי בשם logistic_regression_results.txt שתחת results.

חלק מהקובץ logistic_regression_results.txt:


```

results > logistic_regression_results.txt
1  =====
2  Analysis: Combined (EGFR & KRAS)
3  =====
4  Intercept: -0.0967
5  Coefficient (is_in_domain): 0.1094
6  Odds Ratio: 1.1156
7  P-value (is_in_domain): 7.4172e-01
8
9  Classification Report:
10 |         |         |         | precision    recall  f1-score   support
11 |         |         |         |-----|-----|-----|
12 |         |         |         | 0         0.98      0.15      0.26      271
13 |         |         |         | 1         0.03      0.89      0.06        9
14 |         |         |         |-----|-----|-----|
15 |         | accuracy |         |         0.17      280
16 |         | macro avg |         | 0.50      0.52      0.16      280
17 |         | weighted avg |         | 0.95      0.17      0.25      280
18
19
20 =====
21 Analysis: EGFR Only
22 =====
23 Intercept: 0.5015

```

בפרויקט זה ניתן לבחור בשתי גרסאות שונות של דומיינים פונקציונליים לכל חלבון. בכדי לראות את הדומיינים השונים בכל גרסה, יש להיכנס לקובץ `config_data.py` שתחת `scripts`. בכדי לשנות את גרסאות הדומיינים, יש לשנות את ערכי המשתנים שלהלן:

```

'''
For KRAS choose:
KRAS_DOMAINS_BY_DEFINITION OR KRAS_ALL_REGIONS_WITH_FUNCTION

For EGFR choose:
EGFR_DOMAINS_BY_DEFINITION OR EGFR_ALL_REGIONS_WITH_FUNCTION
'''

CHOSEN_KRAS_DOMAINS_DICTIONARY = KRAS_ALL_REGIONS_WITH_FUNCTION
CHOSEN_EGFR_DOMAINS_DICTIONARY = EGFR_ALL_REGIONS_WITH_FUNCTION

```

(שימו לב שגרסת הדומיינים של שני החלבונים זהות. אם לא, תוצאות הרגרסיה יצאו שונות מהצפוי).

טופס דיווח לשימוש בכלי בינה מלאכותית

שם התוכנית:	BioCode	שם המטלה:	פרויקט סוף שנה
תאריך:	18.6.2026	שם התלמידים	איל רייפלר, שקד ברונדווין

1. הצהרת אחריות אישית:

אני מצהיר/ה כי העבודה משקפת את הבנתי האישית. לא העתקתי טקסטים כפי שהם מכלי הבינה המלאכותית ללא עיבוד וניסוח אישי שלי. בדקתי ותיקפתי את כל העובדות המופיעות בעבודה מול מקורות אמין, ולא הזנתי פרטים אישיים או רגישים למערכות ה AI. חתימת התלמידים:


X
איל רייפלר


שקד ברונדווין

2. פירוט השימוש בבינה מלאכותית בתהליך העבודה:

יש למלא את הטבלה הבאה עבור כל שלב בעבודה שבו השתמשת ב-AI, אם לא השתמשת כלל, ציין/י זאת.

שלב/משימה בעבודה (למשל: סיעור מוחות, חיפוש מאמרים, הבנת מושג, שיפור ניסוח)	הפרומפט (הפקודה) הראשוני	שם הכלי למשל : ChatGPT, Elicit, Claude	חשיבה ביקורתית: מה הכלי עשה פחות טוב? (למשל: מידע שגוי שמצאת, טקסט שהיית צריך/ה לשנות)	קישור לשיחה או צילום מסך
מעבר על תיקונים, לימוד של ספריית pandas, לממש את התיקונים הנדרשים	אני עושה עבודה בביולוגיה חישובית (ברמת תיכון). כתבתי הצעת מחקר והמורה נתנה פידבאק. בבקשה תעבור על העבודה ועל הפידבאק ובבקשה תיצור רשימה של בולטים של מה לעשות ולשנות. העבודה שלי:	Gemini	ההסברים שלו לגבי pandas היו לא מובנים בשבילי. הייתי צריך ללכת ליוטיוב ולראות סרטון במקום.	https://gemini.google.com/app/1162aba009731342

https://gemini.google.com/app/b7d3d0e87c217232	במקרה כתבתי לו בצאט עצמו משהו שהוא עשה לא טוב: " אתה לא עשית את מה שרצינו שנעשה אנחנו רוצים לבדוק האם באזורים פונקציונליים זאת אומרת האם באזורים שהם בתוך האם סליחה האם חומצות אמינו שהם בתוך אזורים האם יש לסבירות יותר גבוהה שתתרחש בהם מוטציה תבנה בבקשה שוב את הקוד"	Gemini	אני רוצה לעשות רגרסיה לוגיסטית. יש לי כבר קובץ כפי שניתן לראות. תכתוב קוד בפייטון שעושה לו רגרסיה לוגיסטית, ובבקשה תסביר כל צעד ואת ההגיון שמאחורי כל בחירה שעשית	כתיבת קוד לרגרסיה, הבנת תהליך הרגרסיה, תיקון שגיאות
לא הצלחנו ליצור קישור מהvs code extension	עשה את זה טוב	Claude	אני צריך שתיצור עץ קבצים של הפרויקט	יצירת עץ קבצים
https://gemini.google.com/app/74c5cf4100ca1d308	הסביר את זה ממש טוב	Gemini	what is the relation between coefficient and odds ratio? Coefficient (is_in_domain): 0.6752 Odds Ratio: 1.9645	הבנת הקשר בין coefficient לodds ratio
https://gemini.google.com/app/6701b690d9a2d4f1	הוא גרם לזה להישמע קל מידי ובסוף אחרי בדיקה עצמאית גילינו שזה יותר קשה משהוא אמר	Gemini	תמליץ על שאלות ותיצור עודג שאלות דומות לרמת הקושי של אלה: רשימת נושאי פרויקטים	עזרה בבחירת נושא לעבודה
https://gemini.google.com/app/f07a34b52381ce0d	הוא הציע לנו להתחשב בהמון דברים ספציים ובכמה דברים מאוד קשים כמו להתייחס ל"ציבות קשר בהעברת אותו סרטנים"	Gemini	תגיד הנאם שאלת החקר הזאת טובה ותן שאלות טובות יותר ממנה: מוטציות סרטניות ודומיינים חלבונים שאלת מחקר: האם מוטציות סרטניות נוטות להופיע בדומיינים פונקציונליים מסוימים?	עזרה בהבנת שאלת המחקר

https://gemini.google.com/app/0410d541e5a9c9003	הוא גרם לזה להישמע כאילו זה יהיה כמעט בלתי אפשרי לעבודה שלנו, כשהאמת היא שאפשר לחשב את זה ידנית, אפילו שכפי שהוא אמר מומלץ במחשב.	Gemini	את רגרסיה לוגיסטית צריך לחשב על דף בעצמך או שניתן לבנות תוכנית שתחשב אותו?	שאלה לגבי רגרסיה
https://gemini.google.com/app/3cb9d0ba39ab92b1	כשביקשתי ממנו סיכום של הדומיינים הוא כלל את HVR, מה שגרם לי בטעות לרשום אותו בין הדומיינים. טעות קשה	Gemini	what are the domains of KRAS(amino acids and names): Skip to main content	מציאת הדומיינים של KRAS
https://gemini.google.com/app/55f4ffc2352fc08f	רוב המחקרים שהוא שיתף לא היו קשורים לשאלת חקר.	Gemini	תמשיך את התוצאות ומסקנות	המשך תוצאות ומסקנות מחקר
https://gemini.google.com/app/e8aa47b562b9ba14	הוא הציע לחלק את הדומיינים לכל מיני קבוצות מזרות	Gemini	there is a problem with the data we have: EGFR_DOMAINS = "" (הנתונים עצמם גדולים מידי מכדי להכניס אותם פה) as you can see, the domain cover all the protein, so there are no not in domain amino acids we can check. should we remove some domains?(we need the function ones)	תיקון הדומיינים הפונקציונליים בחלבון EGFR
https://gemini.google.com/app/18003978a8438654	הוא דווקא הסביר ממש טוב למה המודל לא עובד כמו שצריך	Gemini	Intercept: -0.4987 Coefficient (is_in_domain): 0.9582 Odds Ratio: 2.6070	עזרה בניתוח תוצאות הרגרסיה
https://gemini.google.com/app/c8206755fd7af7ce	הוא ממש שיקר ואמר דומיינים לא נכונים. זה שסמכתי על מה שהוא אמר	Gemini	i talked with AI and he told me that i should change the functional domains of	עזרה במציאת הדומיינים של EGFR

	ולא קראתי בעצמי את כל המחקר ממש פגע בנו בהמשך.		EGFR: #EGFR_DOMAINS =	
https://gemini.google.com/app/e6b77471e30343ee	הוא ממש עוד פעם שיקר לי ונתן דומיינים לא נכונים	Gemini	what are the important domain in EGFR: Epidermal Growth Factor Receptor (EGFR)-Mutated Non-Small-Cell Lung Cancer (NSCLC) וכל שאר המאמר	עזרה במציאת הדומיינים הפונקציונליים של EGFR
https://gemini.google.com/app/0e535faabe8b1c88	גם הוא הביא דומיינים לא נכונים	Gemini	i want to do regression on EGFR ans so i need to say on each amino acid if its in domain that is relent to cancer or not. by this artcile give a dictionary of the important domains:	עוד ניסיון למצוא את הדומיינים של EGFR
https://gemini.google.com/app/7f6937d90a0e62ca	עשה אחלה	Gemini	which one is better: Success! Data table created. Intercept: 0.0344 ועוד שורות של התוצאות אחרי	השוואה בין תוצאות רגרסיה שונות
https://gemini.google.com/app/865ce7a37713b8d2	הסביר טוב	Gemini	in biology what is a functional domain	להבין מה ההגדרה של דומיין פונקציונלי
https://gemini.google.com/app/6191a9359e7381ec	עשה טוב	Gemini	Success! Data table created. Intercept: 0.0344 Coefficient (is_in_domain): -0.0714 Odds Ratio: 0.9311	לנתח את תוצאות הרגרסיה
https://gemini.google.com/app/1593f3d5ee55591c	הסביר טוב	Gemini	in biology what is the difference between a domain and a region	להבין מה ההבדל בין דומיין לאיזור

https://gemini.google.com/app/f7e3afac5885e2d9	שלחתי לו את המסמך עבודה והייתה לי שם שגיאה בהיבט 3, שהוא לא היה נכון ובסוף הייתי צריך להוריד אותו, והוא אמר שהוא נכון.	Gemini	יש לי לדעתי בעיה בעבודה, שאני לא מבין את ההגדרה של functional domain מה זה:	הבנת הדומינים הפונקציונליים
https://gemini.google.com/app/6bcc6d8edf0c66a8	הוא כתב את זה בצורה יותר מידי ספרותית ועם מלא דימויים ומידע לא חשוב. מצמתי את התשובה שלו משמעותית והייתי צריך לנסח מחדש את רוב התשובה	Gemini	אני צריך להסביר בפסקה אחת מה זה NCBI	הסבר מה זה NCBI
https://gemini.google.com/app/548beb689c297131	עשה טוב	Gemini	איזה עוד חלבונים אוניקוגנים נוספים יש כמו EGFR ו-KRAS	איזה עוד חלבונים אוניקוגנים יש
https://gemini.google.com/app/e753a6c2a9767ef2	הוא נתן כל מיני מושגים שבכלל לא מופיעים בעבודה. אמנם הם קשורים לעבודה, אך שמם לא מופיע פה בכלל	Gemini	נכון לכרגע בפרק "מושגי יסוד" יש קצת מאוד מושגים. אני רוצה עוד לפחות 10 מושגים. תכתוב אותם באותו סגנון שכבר כתבתי:	עזרה ביצירת מושגים חדשים
https://gemini.google.com/app/74c5cf4100cad308	הסביר טוב	Gemini	what is the relation between coefficient and odds ratio? Coefficient (is_in_domain): 0.6752 Odds Ratio: 1.9645	הבנת הקשר בין odds ratio לcoefficient
https://gemini.google.com/app/b9b7137a044dfb1e	חישב טוב	Gemini	כמה זה שווה: e-023.4733	עזרה בחישובים מתמטיים
https://gemini.google.com/app/391a9dde51935089	לא הבנתי את ההסבר שלו. האמת שזאת הייתה טעות שלי כי לא צירפתי לו את	Gemini	בבקשה תעבור על זה ותגיד לי אם התוצאה ל EGFR נכונה. זאת אומרת, האם ה odds ratio נכון: תוצאות	וידוא תוצאת רגרסיה

	הנתונים לגבי המוטציות בכל דומיין.		הרגרסייה(logistic_regression): .txt)	
https://gemini.google.com/share/19c8183aced4	תיקנתי טעות של ה-AI שבמקום לבדוק רק איפה המוטציה מתחילה, הקוד שלי בודק את כל הטווח שלה כדי לא לפספס מוטציות שפוגעות בדומיין באמצע	Gemini	תסביר לי בקצרה מה זה מוטציות סרטניות ותן דוגמא לזה ומאיפה אני יכול להוציא קובץ של המוטציות סרטניות והחלבונים	הבנת מושג וחיפוש מאגרי מידע
https://gemini.google.com/share/ffbfa940588f	התשובה שקיבלתי נתנה לי את כל הכלים אבל אמר לי אותם בכלליות ככה שלא הבנתי באמת איך להשתמש בהם ואיך להתקדם לדוגמא: הוא אמר לי להשתמש באתר cBioPortal כדי לקבל את המוטציות בגנים אבל הפער שבין להיכנס לאתר ללהוציא את המידע הספציפי מאוד גדול ולא אפשרי לפי התיאור המינימלי	Gemini	תסביר לי טיפה על המשימה מה היא דורשת ממני בקוד ואיזה סוג מידע ומה אמור להיות לי בקוד(קבצים בדיקה פלט..)	סיעור מוחות